Безградиентная оптимизация при липшицевом шуме

Черновик результатов практикума

Фролов Александр

ноябрь 2026; код и эксперименты — репозиторий `lipnoise-zo`

Цель: найти, какой неслучайный шум в значениях функции допускает двухточечный безградиентный метод для *негладких* выпуклых задач, если шум имеет липшицеву структуру, и доказать, что найденный порог неулучшаем.

Коротко. Для выпуклой M_f-липшицевой задачи на множестве диаметра D шум, представимый в виде суммы M-липшицевой функции и функции с колебанием не больше Δ_0, допустим тогда и только тогда (с точностью до констант и логарифмов), когда

$$M \lesssim \frac{\varepsilon}{D} \qquad \text{и} \qquad \Delta_0 \lesssim \frac{\varepsilon^2}{\sqrt{d}\, M_f D}, \tag{1}$$

причём **амплитуда шума может быть любой**. Липшицева часть допустима на уровне $\Theta(\varepsilon/D)$ без зависимости от размерности. Если же шум может «видеть» текущее случайное направление метода, смещение вырастает до $\sqrt{d}\, M$ (предложение 1).

Положение в литературе (подробно — раздел 6). В негладком двухточечном случае в [8] получено $\varepsilon/(D\sqrt{d})$, и в приложении B авторы пишут, что считают этот порог точным. Мы показываем, что порог равен $\Theta(\varepsilon/D)$. Обе половины этого ответа по сути уже есть в литературе, но не сведены вместе: верхняя оценка без $\sqrt{d}$ (с худшим числом вызовов) — в [1, разд. 4], нижняя оценка $2\varepsilon/R$ — в [9, предложение E.7], а механизм появления $\sqrt{d}$ (шум, видящий случайные направления) — в [9, замечание D.5]. Наш вклад: явная формулировка и полное доказательство с оптимальным числом вызовов, класс шума со скачками Δ_0 и эксперименты с округлением. Технически это сочетание известных приёмов.

1 Постановка

$Q \subset \mathbb{R}^d$, $d \geq 2$, — выпуклое замкнутое множество диаметра D; $f : \mathbb{R}^d \to \mathbb{R}$ выпукла и M_f-липшицева на всём $\mathbb{R}^d$ (запросы могут выходить за Q на расстояние γ); $f^* = \min_Q f$, $x^* \in \arg\min_Q f$. Оракул на запрос $x \in \mathbb{R}^d$ возвращает $\tilde{f}(x) = f(x) + \delta(x)$, где δ — борелевская функция, зафиксированная до запуска (обобщение на шум, зависящий от истории, — предложение 1).

Определение 1. Шум принадлежит классу $\mathcal{N}(M, \Delta_0)$, если

$$|\delta(x) - \delta(y)| \leq \Delta_0 + M\,\|x - y\| \qquad \forall x, y \in \mathbb{R}^d. \tag{2}$$

Частные случаи: $\mathcal{N}(0, 2\Delta)$ содержит любой шум с $|\delta| \leq \Delta$ (ограниченный враждебный шум); $\mathcal{N}(M, 0)$ — M-липшицевы функции (амплитуда не ограничена); округление значений до сетки шага q лежит в $\mathcal{N}(0, q)$. Модель [1, разд. 4] — липшицева часть плюс часть, не зависящая от x, — частный случай с $\Delta_0 = 0$ после сокращения в разности.

Метод. Проекционный двухточечный ZO-SGD: старт $x_0 \in Q$, независимые $e_k \sim \mathrm{Unif}(S^{d-1})$,

$$g_k = \frac{d}{2\gamma}\big(\tilde{f}(x_k + \gamma e_k) - \tilde{f}(x_k - \gamma e_k)\big)e_k, \qquad x_{k+1} = \Pi_Q(x_k - h g_k), \qquad \bar{x}_N = \frac{1}{N}\sum_{k=0}^{N-1} x_k. \tag{3}$$

Обозначим $\mathcal{F}_k = \sigma(e_0, \ldots, e_{k-1})$; точка x_k $\mathcal{F}_k$-измерима, а e_k не зависит от $\mathcal{F}_k$.

2 Вспомогательные факты

Для функции $h : \mathbb{R}^d \to \mathbb{R}$ положим $h_\gamma(x) = \mathbb{E}_u h(x + \gamma u)$, $u \sim \mathrm{Unif}(B^d)$.

Факт A (сглаживание; [3, лемма 1], [2, теорема 1]). *Пусть h непрерывна. Тогда h_γ дифференцируема и*

$$\nabla h_\gamma(x) = \frac{d}{\gamma}\mathbb{E}_e\big[h(x+\gamma e)e\big] = \frac{d}{2\gamma}\mathbb{E}_e\big[(h(x+\gamma e) - h(x-\gamma e))e\big], \qquad e \sim \mathrm{Unif}(S^{d-1}). \tag{4}$$

Если h M-липшицева, то h_γ тоже M-липшицева, поэтому $\|\nabla h_\gamma\| \le M$. Если h выпукла и M-липшицева, то h_γ выпукла и $h \le h_\gamma \le h + \gamma M$.

Первое равенство в (4) — формула Стокса для шара радиуса γ (отношение площади сферы к объёму шара равно d/γ); второе получается заменой $e \mapsto -e$, сохраняющей распределение. Липшицевость h_γ: $|h_\gamma(x) - h_\gamma(y)| \le \mathbb{E}_u |h(x+\gamma u) - h(y+\gamma u)| \le M\|x-y\|$. Неравенство $h \le h_\gamma$ — Йенсен ($\mathbb{E}u = 0$), $h_\gamma \le h + \gamma M$ — липшицевость.

Факт B (концентрация на сфере; [5], [4, лемма 9]). *Пусть $e \sim \mathrm{Unif}(S^{d-1})$, $d \ge 2$. (a) Для любого r: $\mathbb{E}\langle e, r\rangle^2 = \|r\|^2/d$, поэтому $\mathbb{E}|\langle e, r\rangle| \le \|r\|/\sqrt{d}$. (b) Если φ L_φ-липшицева на S^{d-1} (в евклидовой метрике), то $\mathrm{Var}\,\varphi(e) \le L_\varphi^2/(d-1)$ (неравенство Пуанкаре; спектральная щель сферы равна $d-1$).*

Лемма 1 (проекционный SGD со смещённым градиентом). *Пусть $F : \mathbb{R}^d \to \mathbb{R}$ выпукла и дифференцируема, $x_F^* \in \arg\min_Q F$, $x_0 \in Q$. Пусть g_k $\mathcal{F}_{k+1}$-измеримы и почти наверное*

$$\mathbb{E}[g_k \mid \mathcal{F}_k] = \nabla F(x_k) + b_k, \qquad \|b_k\| \le B, \qquad \mathbb{E}[\|g_k\|^2 \mid \mathcal{F}_k] \le G^2.$$

Тогда для $x_{k+1} = \Pi_Q(x_k - h g_k)$

$$\mathbb{E}F(\bar{x}_N) - F(x_F^*) \le \frac{\|x_0 - x_F^*\|^2}{2hN} + \frac{hG^2}{2} + BD. \tag{5}$$

Доказательство. Пусть $r_k = \|x_k - x_F^*\|^2$. Так как $x_F^* \in Q$, проекция не увеличивает расстояние до x_F^*:

$$r_{k+1} \le \|x_k - h g_k - x_F^*\|^2 = r_k - 2h\langle g_k, x_k - x_F^*\rangle + h^2\|g_k\|^2.$$

Возьмём $\mathbb{E}[\cdot \mid \mathcal{F}_k]$; x_k и $x_k - x_F^*$ $\mathcal{F}_k$-измеримы, поэтому

$$\mathbb{E}[r_{k+1} \mid \mathcal{F}_k] \le r_k - 2h\langle \nabla F(x_k) + b_k, x_k - x_F^*\rangle + h^2G^2.$$

По выпуклости $\langle \nabla F(x_k), x_k - x_F^*\rangle \ge F(x_k) - F(x_F^*)$; по Коши–Буняковскому и так как $x_k, x_F^* \in Q$, $|\langle b_k, x_k - x_F^*\rangle| \le BD$. Значит,

$$2h\big(F(x_k) - F(x_F^*)\big) \le r_k - \mathbb{E}[r_{k+1} \mid \mathcal{F}_k] + h^2G^2 + 2hBD.$$

Берём полное матожидание, суммируем по $k = 0, \dots, N-1$ (сумма $r_k - r_{k+1}$ телескопируется и не больше r_0) и делим на $2hN$:

$$\frac{1}{N}\sum_{k=0}^{N-1}\mathbb{E}F(x_k) - F(x_F^*) \le \frac{r_0}{2hN} + \frac{hG^2}{2} + BD.$$

Наконец, по неравенству Йенсена $F(\bar{x}_N) \le \frac{1}{N}\sum_k F(x_k)$. □

3 Структура шума и свойства оценки

Лемма 2 (разложение)**.** *Пусть* $\delta \in \mathcal{N}(M, \Delta_0)$ *и* $\delta_L(x) = \inf_y \big[\delta(y) + M\,\|x - y\|\big]$. *Тогда* δ_L M*-липшицева и* $0 \le \delta - \delta_L \le \Delta_0$. *Обратно, сумма* M*-липшицевой функции и функции со значениями в* $[0, \Delta_0]$ *лежит в* $\mathcal{N}(M, \Delta_0)$.

Доказательство. Подстановка $y = x$ даёт $\delta_L \le \delta$. По (2) $\delta(y) + M\,\|x - y\| \ge \delta(x) - \Delta_0$ для всех y, откуда $\delta_L \ge \delta - \Delta_0 > -\infty$. Нижняя грань семейства M-липшицевых функций $x \mapsto \delta(y) + M\,\|x - y\|$, конечная хотя бы в одной точке, конечна всюду и M-липшицева. Обратно: если $\delta = \ell + \beta$ с M-липшицевой ℓ и $\beta \in [0, \Delta_0]$, то $|\delta(x) - \delta(y)| \le M\,\|x - y\| + |\beta(x) - \beta(y)| \le M\,\|x - y\| + \Delta_0$. □

Лемма 3 (смещение и второй момент)**.** *Пусть* $\delta \in \mathcal{N}(M, \Delta_0)$ *борелевская, и* $g = \frac{d}{2\gamma}\big(\tilde f(x + \gamma e) - \tilde f(x - \gamma e)\big)e$ *при фиксированном* x *и* $e \sim \mathrm{Unif}(S^{d-1})$. *Тогда*

$$\mathbb{E}_e g = \nabla f_\gamma(x) + b(x), \qquad \|b(x)\| \le M + \frac{\sqrt{d}\,\Delta_0}{2\gamma}, \tag{6}$$

$$\mathbb{E}_e\,\|g\|^2 \le 4d(M_f + M)^2 + \frac{d^2\Delta_0^2}{2\gamma^2}. \tag{7}$$

Доказательство. Разложим $\delta = \delta_L + \delta_B$ по лемме 2: δ_L M-липшицева, $\delta_B = \delta - \delta_L$ борелевская со значениями в $[0, \Delta_0]$. Соответственно $g = g_1 + g_2$, где g_1 построена по непрерывной функции $f + \delta_L$, а g_2 — по δ_B.

Смещение. По факту A, применённому к f и к δ_L, $\mathbb{E}g_1 = \nabla f_\gamma(x) + \nabla(\delta_L)_\gamma(x)$ и $\|\nabla(\delta_L)_\gamma(x)\| \le M$. Для единичного r, так как $|\delta_B(a) - \delta_B(b)| \le \Delta_0$, по факту B(a)

$$|\langle \mathbb{E}g_2, r\rangle| \le \frac{d}{2\gamma}\Delta_0\,\mathbb{E}\,|\langle e, r\rangle| \le \frac{\sqrt{d}\,\Delta_0}{2\gamma}.$$

Супремум по r даёт $\|\mathbb{E}g_2\| \le \sqrt{d}\Delta_0/(2\gamma)$. Полагаем $b = \nabla(\delta_L)_\gamma(x) + \mathbb{E}g_2$.

Второй момент. $\|g\|^2 \le 2\,\|g_1\|^2 + 2\,\|g_2\|^2$. Функция $\varphi(e) = (f + \delta_L)(x + \gamma e)$ является $\gamma(M_f + M)$-липшицевой на сфере, $\|g_1\|^2 = \frac{d^2}{4\gamma^2}(\varphi(e) - \varphi(-e))^2$ и $(\varphi(e) - \varphi(-e))^2 \le 2(\varphi(e) - \mathbb{E}\varphi)^2 + 2(\varphi(-e) - \mathbb{E}\varphi)^2$. Так как $-e$ распределён так же, как e, по факту B(b)

$$\mathbb{E}\,\|g_1\|^2 \le \frac{d^2}{4\gamma^2}\cdot 4\,\frac{\gamma^2(M_f + M)^2}{d - 1} = \frac{d^2(M_f + M)^2}{d - 1} \le 2d(M_f + M)^2.$$

Наконец, $\|g_2\|^2 \le \frac{d^2}{4\gamma^2}\Delta_0^2$. □

Замечание. Смещение от липшицевой части не содержит ни $\sqrt{d}$, ни деления на γ, тогда как скачки дают $\sqrt{d}\Delta_0/(2\gamma)$. Численная проверка — эксперимент E1 и тесты в файле `tests/test_theory.py`.

4 Верхняя оценка

Теорема 1. *Пусть выполнены предположения раздела 1,* $\varepsilon \le M_f D$, $\gamma = \varepsilon/(3M_f)$, $G^2 = 5d(M_f + M)^2$, $h = D/(G\sqrt{N})$, *и шум* $\delta \in \mathcal{N}(M, \Delta_0)$ *удовлетворяет*

$$M \le \frac{\varepsilon}{6D}, \qquad \Delta_0 \le \frac{\varepsilon^2}{9\sqrt{d}\,M_f D}. \tag{8}$$

Тогда метод (3) *после* $N = \lceil 45\,d(M_f + M)^2 D^2/\varepsilon^2 \rceil$ *итераций, то есть* $T = 2N$ *вызовов оракула, выдаёт* $\bar x_N \in Q$ *с* $\mathbb{E}f(\bar x_N) - f^* \le \varepsilon$. *Амплитуда шума в условия не входит.*

Доказательство. Шаг 1 (условные моменты). Так как e_k не зависит от $\mathcal{F}_k$, x_k $\mathcal{F}_k$-измерима, а δ фиксирована, условное распределение g_k при данном $\mathcal{F}_k$ — это распределение оценки леммы 3 в точке x_k. Поэтому $\mathbb{E}[g_k \mid \mathcal{F}_k] = \nabla f_\gamma(x_k) + b(x_k)$ и

$$\|b(x_k)\| \le \frac{\varepsilon}{6D} + \frac{\sqrt{d}\Delta_0}{2\gamma} \le \frac{\varepsilon}{6D} + \frac{\sqrt{d}}{2} \cdot \frac{3M_f}{\varepsilon} \cdot \frac{\varepsilon^2}{9\sqrt{d}M_f D} = \frac{\varepsilon}{3D} =: B.$$

Аналогично $\frac{d^2\Delta_0^2}{2\gamma^2} = \frac{d\varepsilon^2}{18D^2} \le \frac{dM_f^2}{18} \le d(M_f + M)^2$ (использовано $\varepsilon \le M_f D$), так что $\mathbb{E}[\|g_k\|^2 \mid \mathcal{F}_k] \le 5d(M_f + M)^2 = G^2$.

Шаг 2 (главная лемма). Функция $F = f_\gamma$ выпукла и дифференцируема (факт A). Лемма 1 с $\|x_0 - x_F^*\| \le D$ и $h = D/(G\sqrt{N})$ даёт

$$\mathbb{E} f_\gamma(\bar{x}_N) - \min_Q f_\gamma \le \frac{D^2}{2hN} + \frac{hG^2}{2} + BD = \frac{DG}{\sqrt{N}} + \frac{\varepsilon}{3} \le \frac{\varepsilon}{3} + \frac{\varepsilon}{3},$$

так как $N \ge 45d(M_f + M)^2 D^2/\varepsilon^2 = 9D^2G^2/\varepsilon^2$.

Шаг 3 (от f_γ к f). По факту A $f \le f_\gamma$ и $\min_Q f_\gamma \le f_\gamma(x^*) \le f^* + \gamma M_f = f^* + \varepsilon/3$. Складывая, получаем $\mathbb{E} f(\bar{x}_N) - f^* \le \varepsilon$. □

Замечание. Число вызовов $T = O(d(M_f + M)^2 D^2/\varepsilon^2)$ оптимально по d и ε [6]. Константы осторожные: в эксперименте E4(a) с параметрами теоремы фактическая ошибка не превосходит $0{,}09\varepsilon$. Батчированный ускоренный вариант с $O(d^{1/4}M_f D/\varepsilon)$ раундами — следующий шаг; для него нужна устойчивость ускоренного метода к аддитивному смещению при ограниченной траектории.

Предложение 1 (шум, зависящий от истории)**.** *(a) Пусть на шаге k оракул использует свой шум $\delta_k \in \mathcal{N}(M, \Delta_0)$, выбранный по всей истории (то есть δ_k определяется $\mathcal{F}_k$, а отображение $(\omega, x) \mapsto \delta_k(x)$ измеримо по совокупности), но не по текущему направлению e_k. Тогда утверждение теоремы 1 сохраняется.*

(b) Если шум может зависеть от e_k, то уже при $\Delta_0 = 0$ смещение может достигать $dM\,\mathbb{E}\,|\langle e, v\rangle| \approx \sqrt{2d/\pi}\,M$: например, $\delta_k(x) = M \operatorname{sign}\langle e_k, v\rangle\ \langle e_k, x - x_k\rangle$ с единичным v даёт $\mathbb{E}[g_k \mid \mathcal{F}_k] = \nabla f_\gamma(x_k) + dM\,\mathbb{E}\,|\langle e, v\rangle|\ v$.

Доказательство. (a) В шаге 1 доказательства теоремы 1 использовалось лишь то, что при фиксированной $\mathcal{F}_k$ шум — фиксированная функция класса $\mathcal{N}(M, \Delta_0)$, не зависящая от e_k; лемма 3 применяется условно (по лемме о замораживании, для чего и нужна совместная измеримость). Остальное без изменений. Отметим, что сами точки запросов $x_k \pm \gamma e_k$ раскрывают e_k, поэтому требование «шум не видит e_k» означает, что функция δ_k выбрана до запросов шага k.

(b) Функция δ_k M-липшицева. В точках $x_k \pm \gamma e_k$ она равна $\pm\gamma M \operatorname{sign}\langle e_k, v\rangle$, поэтому шумовая часть оценки равна

$$\frac{d}{2\gamma} \cdot 2\gamma M \operatorname{sign}\langle e_k, v\rangle\ e_k = dM \operatorname{sign}\langle e_k, v\rangle\ e_k, \qquad \mathbb{E}\big[\operatorname{sign}\langle e, v\rangle\ e\big] = \mathbb{E}\,|\langle e, v\rangle|\ v$$

(второе равенство — по симметрии). Наконец, $d\,\mathbb{E}\,|\langle e, v\rangle| = d\,\Gamma(d/2)/(\sqrt{\pi}\,\Gamma((d+1)/2)) \sim \sqrt{2d/\pi}$. □

Замечание. Предложение 1(b) объясняет оценку $\sqrt{d}\,M_\delta$ из [8]: такой порядок смещения возможен, только если шум знает текущее случайное направление метода. Та же конструкция для оценки по «рамкам» направлений приведена в [9, замечание D.5]; здесь она повторена для двухточечной оценки Шамира. Для шума, фиксированного заранее (как в [8]) или подстраивающегося лишь под прошлое, смещение не больше M.

5 Нижняя оценка по липшицевой части

Теорема ниже по существу содержится в [9, предложение E.7]: там нижняя оценка $M_{\max} \le 2\varepsilon/R$ доказана для любого класса, содержащего выпуклые квадратичные функции с ограниченным гессианом (пара: квадратичная функция плюс линейный шум); на ограниченном Q такие функции липшицевы, так что оценка покрывает и наш класс. Мы приводим вариант с парой линейных функций ради полноты.

Теорема 2. *Пусть Q — шар радиуса $\rho = D/2$ с центром в нуле, $\varepsilon < M_f\rho$, и $M > 2\varepsilon/D$. Тогда для любого алгоритма (рандомизированного, адаптивного, с любым конечным числом запросов в любых точках $\mathbb{R}^d$ и выходом $\hat{x} \in Q$) найдутся выпуклая M_f-липшицева f и шум $\delta \in \mathcal{N}(M, 0)$, при которых $\mathbb{E}f(\hat{x}) - f^* > \varepsilon$.*

Доказательство. Интервал $(2\varepsilon/D, \min\{M, M_f\}]$ непуст, так как $M > 2\varepsilon/D$ и $M_f > \varepsilon/\rho = 2\varepsilon/D$. Возьмём a из него, единичный u и $f_\pm(x) = \pm a\,\langle u, x\rangle$, $\delta_\pm = -f_\pm$. Функции $f_\pm$ выпуклы и a-липшицевы, шум a-липшицев, то есть $\delta_\pm \in \mathcal{N}(M, 0)$. Оракул в обоих случаях на любой запрос отвечает нулём, поэтому совместное распределение запросов, ответов и выхода $\hat{x}$ одинаково для f_+ и f_-. Так как $\min_Q f_\pm = -a\rho$,

$$\mathbb{E}[f_+(\hat{x}) - f_+^*] + \mathbb{E}[f_-(\hat{x}) - f_-^*] = \mathbb{E}\big[a\,\langle u, \hat{x}\rangle + a\rho - a\,\langle u, \hat{x}\rangle + a\rho\big] = aD > 2\varepsilon,$$

и одно из слагаемых больше ε. □

Следствие 1. *Допустимый уровень липшицевой части равен $\Theta(\varepsilon/D)$: теоремы 1 и 2 расходятся лишь в константе 12, и порог не зависит от d и от амплитуды. Для скачков при $M = 0$ класс $\mathcal{N}(0, 2\Delta)$ содержит ограниченный шум $|\delta| \le \Delta$, для которого нижняя оценка [7] даёт $\Delta_{\max} \lesssim \max\{\varepsilon^2/(\sqrt{d}M_fD),\ \varepsilon/d\}$ с точностью до логарифмов (для алгоритмов с полиномиальным числом запросов). При $\varepsilon \gtrsim M_fD/\sqrt{d}$ первая ветвь больше, и условие на Δ_0 в (8) точно с точностью до констант и логарифмов. В этом режиме область (1) точна по обеим осям.*

Предложение 2 (Г-образная область)**.** *«Рампа» $\psi(x) = \Delta\,\mathrm{clip}(M\,\langle u, x\rangle/\Delta, -1, 1)$ лежит и в $\mathcal{N}(M, 0)$, и в $\mathcal{N}(0, 2\Delta)$. Поэтому теорема 1 применима к ней, если* либо $M \le \varepsilon/(6D)$, либо $2\Delta \le \varepsilon^2/(9\sqrt{d}M_fD)$*: область безвредности в плоскости (Δ, M) имеет форму буквы «Г».*

Доказательство. ψ — композиция 1-липшицевой функции clip, умноженной на Δ, с M/Δ-липшицевой функцией $x \mapsto M\,\langle u, x\rangle/\Delta$, поэтому она M-липшицева; кроме того, $|\psi| \le \Delta$, и $|\psi(x) - \psi(y)| \le 2\Delta$. □

6 Связь с литературой

- [1, разд. 4] (2016): негладкие задачи, двухточечная схема, шум — липшицева часть плюс часть, не зависящая от x. Допустимость выведена из условия $\|\nabla\mathbb{E}\delta(x + \tau\tilde{s})\| = O(\varepsilon/R)$, а оно выполняется для шума с константой Липшица $O(\varepsilon/R)$ — то же наблюдение, что лемма 3. Это и есть верхняя оценка без $\sqrt{d}$; число вызовов $n^2M^2R^2/\varepsilon^2$ (в n раз хуже оптимального), оптимальность оставлена открытой (сноска 46).
- [8] (v3, 2023): негладкие выпуклые и седловые задачи, двухточечная схема, M_δ-липшицев шум, фиксированный заранее (Assumption 2.3). Смещение оценено как $\sqrt{d}\,M_\delta$ (формула (62)), отсюда $M_\delta \lesssim \varepsilon/(D\sqrt{d})$ (следствие 3.2 и замечание 1 после него). В приложении B, формулы (69)–(71), выведены два «верхних» порога: $\varepsilon/(D\sqrt{d})$ при условии, что точки запросов не зависят от выборки, и ε/D в общем

случае, и сказано: «We believe that (71) is not tight upper bound, rather than (69)», то есть авторы считают точным $\varepsilon/(D\sqrt{d})$. Для глобально липшицева шума это противоречит уже [1] и теоремам 1, 2.

- [9] (октябрь 2026): функции гёльдеровой гладкости $\beta > 2$. Для систематической M-липшицевой ошибки: для выпуклых $\varepsilon/(16R) \le M_{\max} \le 2\varepsilon/R$ (теорема 5(b)); верхняя оценка использует ограниченный гессиан. Нижняя оценка (предложение E.7) сформулирована для любого класса, содержащего квадратичные функции, и потому годится и для негладкого случая. Замечание D.5: шум, выбранный после того, как стали известны случайные направления, сдвигает оценку на $\sqrt{d}\,M$. В обзоре литературы этой работы негладкий случай по-прежнему указан с порогом $\varepsilon/(R\sqrt{d})$ из [8].

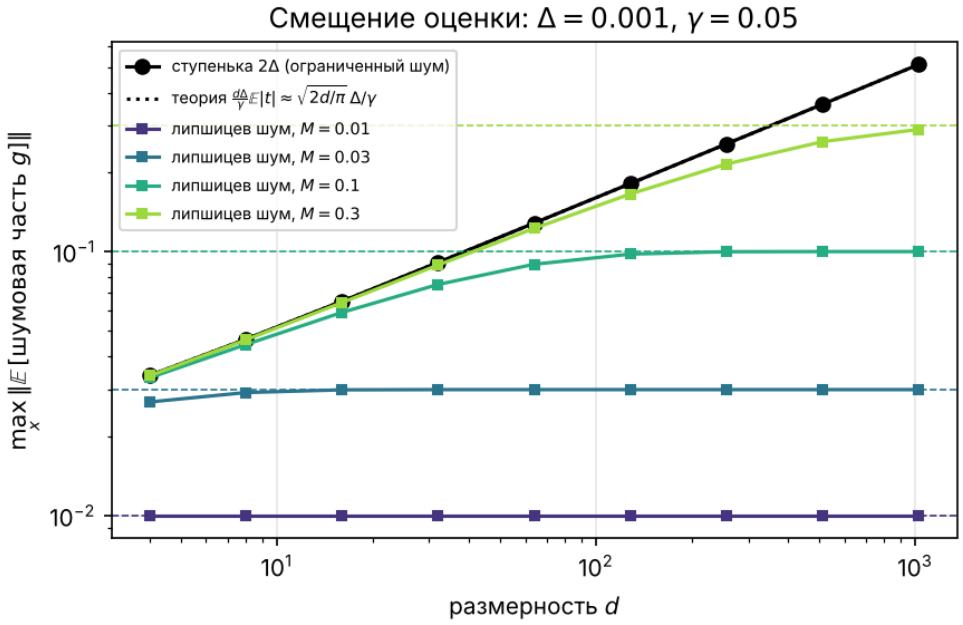
Что здесь нового. По отдельности нижняя оценка, верхняя оценка без $\sqrt{d}$ и механизм появления $\sqrt{d}$ уже есть в [1, 9]. Наш вклад: (1) явная формулировка и полное доказательство порога $\Theta(\varepsilon/D)$ для негладких функций в двухточечной схеме с оптимальным числом вызовов $O(dM_f^2D^2/\varepsilon^2)$ — это снимает гипотезу из приложения B [8] для глобально липшицева шума; (2) класс $\mathcal{N}(M, \Delta_0)$ со скачками, зависящими от x, и Г-образная область; (3) эксперименты, в частности эмпирический закон мёртвой зоны при округлении. Это аккуратная заметка, а не статья.

Открытый вопрос. Мотивировка гипотезы в [8, прил. B] — шум выборочного среднего $F - \hat{F}$, который липшицев с константой $M/\sqrt{N}$ лишь на запрошенных точках, а глобально — с константой $\sqrt{d}\,M/\sqrt{N}$ (их формула (70)). Нужен ли множитель $\sqrt{d}$ для шума, липшицева только на запрошенных точках, по-видимому, открыто.

7 Эксперименты

Код: `lipzo/` (модели шума, оценка, метод), `tests/` (24 теста: численные проверки лемм, предложений и короткий прогон теоремы 1), `experiments/` (всё воспроизводится одной командой `bash run_all.sh`). Подробные описания — `docs/experiments.md`.

E1. Смещение в зависимости от размерности. Шум направлен вдоль одной оси, поэтому среднее оценки вычисляется точно одномерной квадратурой (без Монте-Карло). Ступенька высоты 2Δ даёт смещение, растущее как $\sqrt{2d/\pi}\,\Delta/\gamma$; липшицева рампа даёт смещение, ограниченное наклоном M при всех d (при $d \ge 128$ отношение к M равно 1,000).



E2. Фазовый переход в плоскости (Δ, M). Постановка слайда 29 доклада: $f(x) = -g_0 \langle u, x\rangle$ на единичном шаре, $g_0 = 2\varepsilon/R$, $\varepsilon = 0{,}1$, шум — «стена» поперёк гиперплоскости $\langle u, x\rangle = 0$, старт $x_0 = -0{,}6u$, $d = 20$, $\gamma = 0{,}05$, 3000 итераций, 16 запусков на клетку. Предсказание «метод блокируется $\iff$ максимальное смещение больше g_0» совпадает с экспериментом в 97,6% клеток. Расхождения — столбец $M \approx 0{,}16$ чуть ниже порога $g_0 = 0{,}2$: там стена не блокирует, а замедляет метод (суммарный наклон 0,04), и при 10^4 итерациях все запуски успешны; при $M = 0{,}25 > g_0$ неудача сохраняется при любом бюджете.

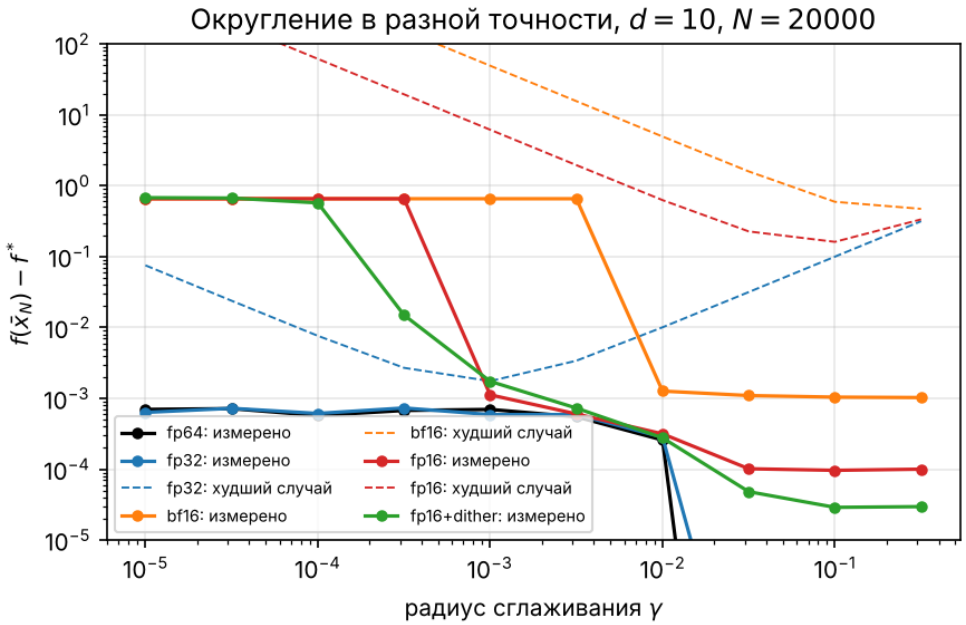


E3. Реальное округление. $f(x) = 1 + \|x - c\|_1 / \sqrt{d}$ ($M_f = 1$), $d = 10$, $2 \cdot 10^4$ итераций; значения вычисляются в fp64, fp32, bf16, fp16 и fp16 со стохастическим округлением (случайный последний бит, как в [1, разд. 4]). Наблюдения:

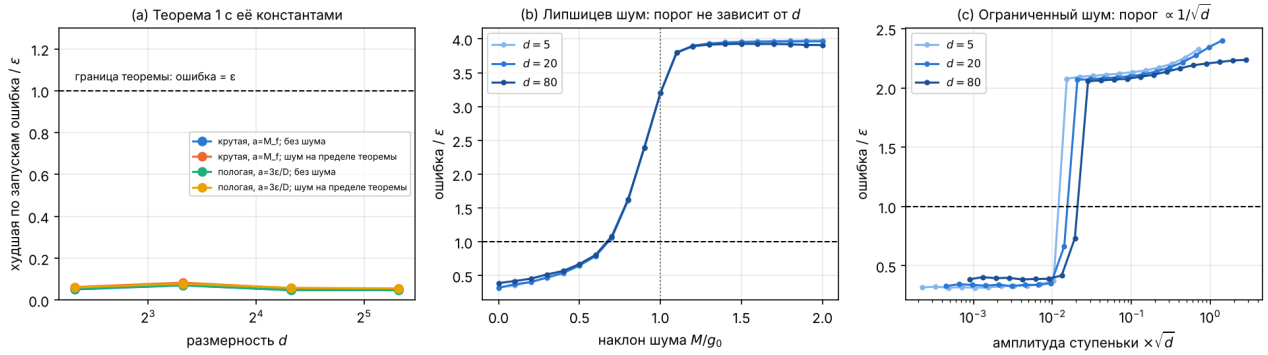
1. Оценка худшего случая $M_f\gamma + D\sqrt{d}\Delta_0/(2\gamma)$ (пунктир) пессимистична на 2–3 порядка: при достаточно большом γ округление практически безвредно.

2. При малом γ механизм отказа другой: значения в $x \pm \gamma e$ округляются в одно число, оценка равна нулю, и метод стоит на месте («мёртвая зона»). Порог по γ у bf16 в $8 = 2^3$ раза больше, чем у fp16 — ровно разница мантисс.

3. Стохастическое округление сдвигает мёртвую зону примерно втрое и снижает итоговую ошибку; при совсем малых γ мешает уже дисперсия d^2q^2/γ^2.

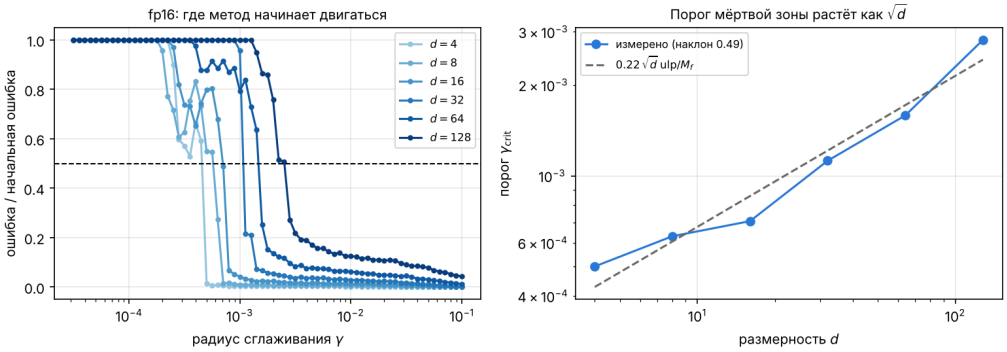


E4. Проверка теорем 1 и 2. (a) Теорема 1 с её собственными константами ($\varepsilon = 0{,}2$, $D = 2$, $M_f = 1$, $d \in \{5, 10, 20, 40\}$, N от $2{,}3 \cdot 10^4$ до $1{,}9 \cdot 10^5$) на крутой ($a\,\|x - c\|$, $a = 1$) и пологой ($a = 3\varepsilon/D$) функциях, без шума и с шумом на пределе условий (8): худшая по 8 запускам ошибка не превосходит $0{,}083\varepsilon$, то есть оценка выполняется с запасом примерно в 12 раз. (b) Липшицев «встречный» шум на линейной функции: зависимость ошибки от M/g_0 одна и та же при $d = 5, 20, 80$ — порог не зависит от размерности. (c) Ступенчатый (ограниченный) шум: в координатах «амплитуда $\times\sqrt{d}$» пороги для разных d почти совпадают, то есть порог ограниченного шума $\propto 1/\sqrt{d}$.



E5. Закон мёртвой зоны. $f(x) = 1 + \|x - c\|_1/\sqrt{d}$ в fp16, $d \in \{4, \ldots, 128\}$, сетка из 71 значения γ. Порог γ_{crit} — наименьший γ, при котором ZO-SGD за 3000 шагов вдвое уменьшает начальную ошибку. Эвристика: разность $f(x+\gamma e) - f(x-\gamma e) \approx 2\gamma\,\langle \nabla f, e\rangle \sim 2\gamma M_f/\sqrt{d}$

должна превысить шаг округления q, откуда $\gamma_{\text{crit}} \propto \sqrt{d}\, q/M_f$. Измеренный наклон $\log \gamma_{\text{crit}}$ по $\log d$ равен 0,49, а $\gamma_{\text{crit}} \approx 0{,}2\sqrt{d}\, q/M_f$ при всех d от 4 до 128.



8 Следующие шаги и вопросы

1. Ускоренный батчированный вариант теоремы 1 (три критерия: T, N, допустимый шум).
2. Модель округления: доказать закон мёртвой зоны $\gamma_{\text{crit}} \asymp \sqrt{d}\, q/M_f$ (E5) и оценку для «почти случайного» округления, объясняющую E3.
3. Шум, видящий текущее направление: предложение 1(b) даёт пример со смещением $\sqrt{d}M$; совпадает ли с ним верхняя оценка в этой модели?
4. Шум, липшицев только на запрошенных точках (мотивировка гипотезы [8, прил. B]): нужен ли там множитель $\sqrt{d}$?
5. Формализация теоремы 1 в LongTails. Основа — готовый Setup `AdaptivePairedZerothOrder`, в котором условие $|\delta| \le \Delta$ заменяется на (2).

Вопросы к А. В. Гасникову: (1) какая модель липшицева шума имелась в виду; (2) стоит ли оформить негладкий случай как короткую заметку или сразу двигаться к продолжению (теория округления, ускорение); (3) нужен ли «кубик» адаптивности; (4) допустимо ли использовать LongTails в курсовой работе.

Список литературы

[1] А. В. Гасников, П. Е. Двуреченский, Ю. Е. Нестеров. Стохастические градиентные методы с неточным оракулом. arXiv:1411.4218 (2016).

[2] A. Gasnikov et al. Randomized gradient-free methods in convex optimization. arXiv:2211.13566.

[3] A. Flaxman, A. Kalai, H. B. McMahan. Online convex optimization in the bandit setting: gradient descent without a gradient. SODA 2005.

[4] O. Shamir. An optimal algorithm for bandit and zero-order convex optimization with two-point feedback. JMLR 18 (2017).

[5] M. Ledoux. The concentration of measure phenomenon. AMS, 2001.

[6] J. Duchi, M. Jordan, M. Wainwright, A. Wibisono. Optimal rates for zero-order convex optimization: the power of two function evaluations. IEEE Trans. Inf. Theory, 2015.

[7] A. Risteski, Y. Li. Algorithms and matching lower bounds for approximately-convex optimization. NeurIPS 2016.

[8] D. Dvinskikh, V. Tominin, Y. Tominin, A. Gasnikov. Gradient-free optimization for non-smooth minimax problems with maximum value of adversarial noise. arXiv:2202.06114 (v3, 2023).

[9] T. Loginov, D. Dvinskikh, N. Tupitsa, O. Osmanov, Y. Dorn, A. Gasnikov. Minimax oracle call complexity, rounds and admissible noise in zeroth-order optimization of highly smooth functions. arXiv:2610.05517 (2026).