Безградиентная оптимизация при липшицевом шуме

Черновик результатов практикума

Фролов Александр

ноябрь 2026; код и эксперименты — репозиторий `lipnoise-zo`

Цель: найти, какой неслучайный шум в значениях функции допускает двухточечный безградиентный метод, если шум имеет липшицеву структуру, и доказать, что найденный порог неулучшаем.

Коротко. Для выпуклой M_f-липшицевой задачи на множестве диаметра D шум, представимый в виде суммы M-липшицевой функции и функции с колебанием не больше Δ_0, допустим тогда и только тогда (с точностью до констант и логарифмов), когда

$$M \lesssim \frac{\varepsilon}{D} \qquad \text{и} \qquad \Delta_0 \lesssim \frac{\varepsilon^2}{\sqrt{d}\, M_f D}, \tag{1}$$

причём **амплитуда шума может быть любой**. Липшицева часть допустима на уровне $\Theta(\varepsilon/D)$ без зависимости от размерности; это отвечает на вопрос об оптимальности из [1] (сноска 46) для негладкого двухточечного случая.

1 Постановка

$Q \subset \mathbb{R}^d$ — выпуклое замкнутое множество диаметра D; $f : \mathbb{R}^d \to \mathbb{R}$ выпукла и M_f-липшицева; $f^* = \min_Q f$. Оракул на запрос $x \in \mathbb{R}^d$ возвращает $\tilde{f}(x) = f(x) + \delta(x)$, где δ — детерминированная функция, зафиксированная до запуска (шум не зависит от случайности метода).

Определение 1. Шум принадлежит классу $\mathcal{N}(M, \Delta_0)$, если

$$|\delta(x) - \delta(y)| \le \Delta_0 + M\,\|x - y\| \qquad \forall x, y \in \mathbb{R}^d. \tag{2}$$

Частные случаи: $\mathcal{N}(0, 2\Delta)$ содержит любой шум с $|\delta| \le \Delta$ (ограниченный враждебный шум); $\mathcal{N}(M, 0)$ — M-липшицевы функции (амплитуда не ограничена); округление значений до сетки шага q лежит в $\mathcal{N}(0, q)$. Модель [1, разд. 4] — липшицева часть плюс часть, не зависящая от x, — частный случай с $\Delta_0 = 0$ после сокращения в разности.

Метод. Проекционный двухточечный ZO-SGD: $e_k \sim \mathrm{Unif}(S^{d-1})$,

$$g_k = \frac{d}{2\gamma}\big(\tilde{f}(x_k + \gamma e_k) - \tilde{f}(x_k - \gamma e_k)\big)e_k, \qquad x_{k+1} = \Pi_Q(x_k - h g_k), \qquad \bar{x}_N = \frac{1}{N}\sum_{k=0}^{N-1} x_k. \tag{3}$$

2 Структура шума и свойства оценки

Лемма 1 (разложение)**.** *Пусть $\delta \in \mathcal{N}(M, \Delta_0)$ и $\delta_L(x) = \inf_y\big[\delta(y) + M\,\|x - y\|\big]$. Тогда δ_L M-липшицева и $0 \le \delta - \delta_L \le \Delta_0$. Обратно, сумма M-липшицевой функции и функции со значениями в $[0, \Delta_0]$ лежит в $\mathcal{N}(M, \Delta_0)$.*

Доказательство. Подстановка $y = x$ даёт $\delta_L \le \delta$. По (2) $\delta(y) + M\,\|x - y\| \ge \delta(x) - \Delta_0$ для всех y, откуда $\delta_L \ge \delta - \Delta_0 > -\infty$. Нижняя грань семейства M-липшицевых функций $x \mapsto \delta(y) + M\,\|x - y\|$, конечная хотя бы в одной точке, M-липшицева. Обратное утверждение очевидно. □

Обозначим $h_\gamma(x) = \mathbb{E}_u h(x + \gamma u)$, $u \sim \mathrm{Unif}(B^d)$. Для непрерывной h по формуле Стокса $\nabla h_\gamma(x) = \frac{d}{\gamma}\mathbb{E}_e[h(x+\gamma e)e]$, и если h M-липшицева, то h_γ тоже M-липшицева, поэтому $\|\nabla h_\gamma\| \le M$.

Лемма 2 (смещение и второй момент)**.** *Пусть $\delta \in \mathcal{N}(M, \Delta_0)$, $d \ge 2$, и g — оценка (3) в точке x. Тогда*

$$\mathbb{E}_e g = \nabla f_\gamma(x) + b(x), \qquad \|b(x)\| \le M + \frac{\sqrt{d}\,\Delta_0}{2\gamma}, \tag{4}$$

$$\mathbb{E}_e \|g\|^2 \le 4d(M_f + M)^2 + \frac{d^2\Delta_0^2}{2\gamma^2}. \tag{5}$$

Доказательство. Разложим $\delta = \delta_L + \delta_B$ по лемме 1, $\delta_B \in [0, \Delta_0]$. По формуле Стокса (в симметризованном виде) часть оценки, порождённая $f + \delta_L$, имеет среднее $\nabla f_\gamma + \nabla(\delta_L)_\gamma$, и $\|\nabla(\delta_L)_\gamma\| \le M$. Для части β, порождённой δ_B, при единичном r, так как $|\delta_B(a) - \delta_B(b)| \le \Delta_0$ и $\mathbb{E}\,|\langle e, r\rangle| \le 1/\sqrt{d}$,

$$\langle \mathbb{E}\beta, r\rangle \le \frac{d}{2\gamma}\Delta_0\,\mathbb{E}\,|\langle e, r\rangle| \le \frac{\sqrt{d}\Delta_0}{2\gamma}.$$

Для второго момента $\|g\|^2 \le 2\|g_1\|^2 + 2\|g_2\|^2$, где g_1 порождена $f + \delta_L$, а g_2 — δ_B. Функция $\varphi(e) = (f + \delta_L)(x + \gamma e)$ является $\gamma(M_f + M)$-липшицевой на сфере, и по неравенству Пуанкаре $\mathbb{E}\|g_1\|^2 \le \frac{d^2}{4\gamma^2} \cdot \frac{4\gamma^2(M_f+M)^2}{d-1} \le 2d(M_f + M)^2$. Наконец, $\|g_2\|^2 \le \frac{d^2\Delta_0^2}{4\gamma^2}$. □

Замечание. Смещение от липшицевой части не содержит ни $\sqrt{d}$, ни деления на γ, тогда как ограниченный шум даёт $\sqrt{d}\Delta_0/\gamma$. Численная проверка — эксперимент E1 и тесты в `tests/test_theory.py`.

3 Верхняя оценка

Теорема 1. *Пусть $\varepsilon \le M_f D$, $\gamma = \varepsilon/(3M_f)$, $h = D/(G\sqrt{N})$ с $G^2 = 5d(M_f + M)^2$, и шум $\delta \in \mathcal{N}(M, \Delta_0)$ удовлетворяет*

$$M \le \frac{\varepsilon}{6D}, \qquad \Delta_0 \le \frac{\varepsilon^2}{9\sqrt{d}\,M_f D}. \tag{6}$$

Тогда метод (3) после $N = \lceil 45\, d(M_f + M)^2 D^2/\varepsilon^2 \rceil$ итераций, то есть $T = 2N$ вызовов оракула, выдаёт $\bar{x}_N \in Q$ с $\mathbb{E}f(\bar{x}_N) - f^* \le \varepsilon$. Амплитуда шума в условия не входит.

Доказательство. По (6) и $\varepsilon \le M_f D$ имеем $\frac{d^2\Delta_0^2}{2\gamma^2} \le \frac{d\varepsilon^2}{18D^2} \le d(M_f + M)^2$, поэтому по (5) $\mathbb{E}\|g_k\|^2 \le G^2$. По (4) $\|b\| \le \frac{\varepsilon}{6D} + \frac{\sqrt{d}\Delta_0}{2\gamma} \le \frac{\varepsilon}{3D} =: B$. Применим основное неравенство для проекционного SGD со смещённым градиентом (методичка, утверждение 3.1) к выпуклой дифференцируемой функции f_γ на Q с минимумом x_γ^*: при $h = D/(G\sqrt{N})$

$$\mathbb{E}f_\gamma(\bar{x}_N) - f_\gamma(x_\gamma^*) \le \frac{DG}{\sqrt{N}} + BD \le \frac{\varepsilon}{3} + \frac{\varepsilon}{3}.$$

Наконец, $f \le f_\gamma$ (Йенсен) и $f_\gamma(x_\gamma^*) \le f_\gamma(x^*) \le f^* + \gamma M_f = f^* + \varepsilon/3$. □

Замечание. Число вызовов $T = O(d(M_f + M)^2 D^2/\varepsilon^2)$ оптимально по d и ε (Duchi et al. 2015). Следующий шаг — батчированный ускоренный вариант с $N = O(d^{1/4} M_f D/\varepsilon)$ раундов; для него нужна теорема об устойчивости ускоренного метода к аддитивному смещению при ограниченной траектории (методичка, §4.4).

4 Нижняя оценка по липшицевой части

Теорема 2. *Пусть Q — шар радиуса $\rho = D/2$ с центром в нуле, $\varepsilon < M_f\rho$, и $M > 2\varepsilon/D$. Тогда для любого (рандомизированного, адаптивного) алгоритма с любым числом запросов в любых точках $\mathbb{R}^d$ найдутся выпуклая M_f-липшицева f и шум $\delta \in \mathcal{N}(M, 0)$, при которых $\mathbb{E}f(\hat{x}) - f^* > \varepsilon$ для выхода $\hat{x} \in Q$.*

Доказательство. Возьмём $a \in (2\varepsilon/D, \min\{M, M_f\}]$, единичный u и $f_\pm(x) = \pm a\langle u, x\rangle$, $\delta_\pm = -f_\pm$. Шум a-липшицев, оракул в обоих случаях всегда отвечает нулём, поэтому распределение $\hat{x}$ одинаково. Так как $\min_Q f_\pm = -a\rho$,

$$\mathbb{E}[f_+(\hat{x}) - f_+^*] + \mathbb{E}[f_-(\hat{x}) - f_-^*] = \mathbb{E}\big[a\langle u, \hat{x}\rangle + a\rho - a\langle u, \hat{x}\rangle + a\rho\big] = aD > 2\varepsilon,$$

и одно из слагаемых больше ε. □

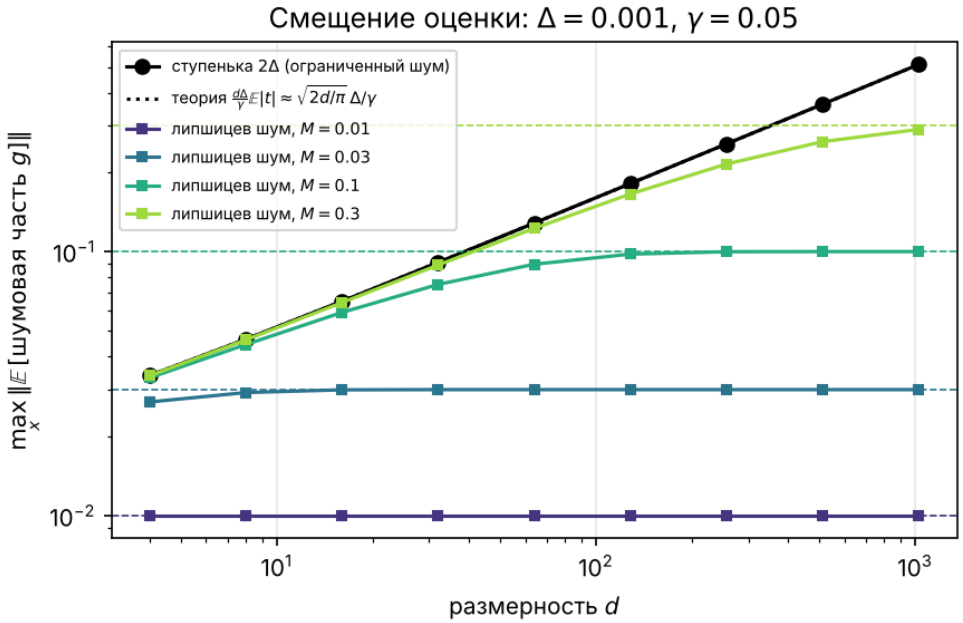
Следствие 1. *Допустимый уровень липшицевой части равен $\Theta(\varepsilon/D)$: теоремы 1 и 2 расходятся лишь в константе 12, и порог не зависит от d и от амплитуды. Для ограниченной части при $M = 0$ нижняя оценка Ристески–Ли $\Delta_{\max} \lesssim \max\{\varepsilon^2/(\sqrt{d}M_f D), \varepsilon/d\}$ (с точностью до логарифмов) показывает, что условие на Δ_0 в (6) неулучшаемо при не слишком малых ε. Поэтому область (1) точна по обеим осям.*

Замечание. Принадлежность классу не единственна: шум малой амплитуды Δ лежит и в $\mathcal{N}(0, 2\Delta)$. Поэтому для «рампы» высоты Δ и наклона M шум безвреден, если *либо* $M \lesssim \varepsilon/D$, *либо* $\Delta \lesssim \varepsilon^2/(\sqrt{d}M_f D)$: область безвредности в плоскости (Δ, M) имеет форму буквы «Г». Это видно в эксперименте E2.

5 Эксперименты

Код: `lipzo/` (модели шума, оценка, метод), `tests/` (6 проверок лемм, 15 тестов), `experiments/` (воспроизведение одной командой `bash run_all.sh`).

E1. Смещение в зависимости от размерности. Шум направлен вдоль одной оси, поэтому среднее оценки вычисляется точно одномерной квадратурой (без Монте-Карло). Ступенька высоты 2Δ даёт смещение, растущее как $\sqrt{2d/\pi}\,\Delta/\gamma$; липшицева рампа даёт смещение, ограниченное наклоном M при всех d (при $d \geq 128$ отношение к M равно 1,000).

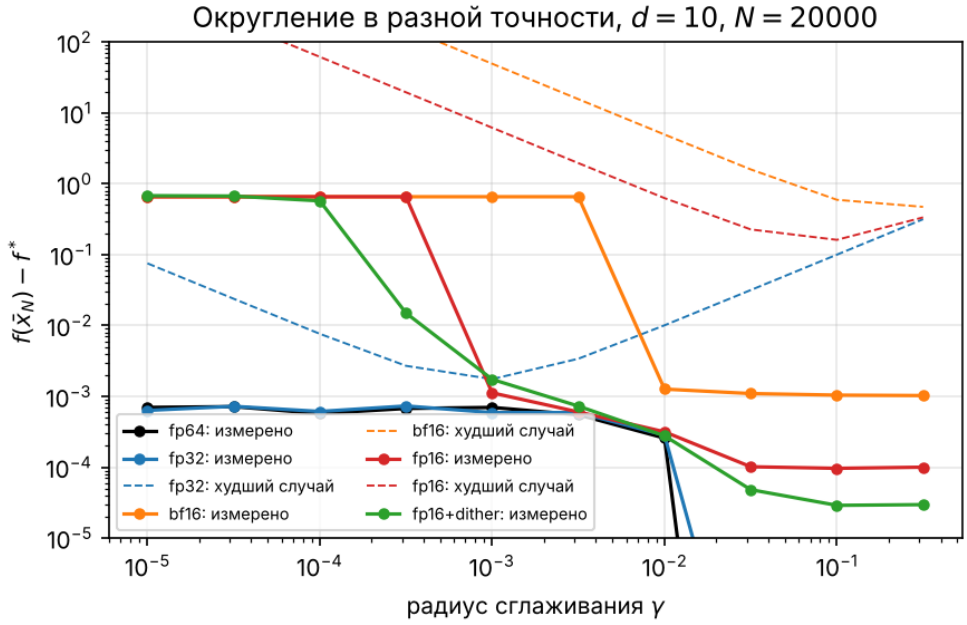


E2. Фазовый переход в плоскости (Δ, M). Постановка слайда 29 доклада: $f(x) = -g_0 \langle u, x\rangle$ на единичном шаре, $g_0 = 2\varepsilon/R$, $\varepsilon = 0{,}1$, шум — «стена» поперёк гиперплоскости $\langle u, x\rangle = 0$, старт $x_0 = -0{,}6u$, $d = 20$, $\gamma = 0{,}05$, 3000 итераций, 16 запусков на клетку. Предсказание «метод блокируется $\iff$ максимальное смещение больше g_0» совпадает с экспериментом в 97,6% клеток. Расхождения — столбец $M \approx 0{,}16$ чуть ниже порога $g_0 = 0{,}2$: там стена не блокирует, а замедляет метод (суммарный наклон 0,04), и при 10^4 итерациях все запуски успешны; при $M = 0{,}25 > g_0$ неудача сохраняется при любом бюджете.



E3. Реальное округление. $f(x) = 1 + \|x - c\|_1 / \sqrt{d}$ ($M_f = 1$), $d = 10$, $2 \cdot 10^4$ итераций; значения вычисляются в fp64, fp32, bf16, fp16 и fp16 со стохастическим округлением (случайный последний бит, как в [1, разд. 4]). Наблюдения:

1. Оценка худшего случая $M_f\gamma + D\sqrt{d}\Delta_0/(2\gamma)$ (пунктир) пессимистична на 2–3 порядка: при достаточно большом γ округление практически безвредно.
2. При малом γ механизм отказа другой: значения в $x \pm \gamma e$ округляются в одно число, оценка равна нулю, и метод стоит на месте («мёртвая зона»). Порог по γ у bf16 в $8 = 2^3$ раза больше, чем у fp16 — ровно разница мантисс; порядок порога $\gamma \sim \sqrt{d}\,\mathrm{ulp}/M_f$.
3. Стохастическое округление сдвигает мёртвую зону примерно втрое и снижает итоговую ошибку; при совсем малых γ мешает уже дисперсия d^2q^2/γ^2.



6 Следующие шаги и вопросы

1. Ускоренный батчированный вариант теоремы 1 (три критерия: T, N, допустимый шум).
2. Модель округления: доказать порог мёртвой зоны $\gamma \gtrsim \sqrt{d}\, q/M_f$ и оценку для случайного (не враждебного) округления, объясняющую E3.
3. Шум, зависящий от истории запросов: верна ли теорема 1, если липшицевость требуется только при фиксированной истории?
4. Формализация теоремы 1 в LongTails. Основа — готовый Setup

   `AdaptivePairedZerothOrder`, в котором условие $|\delta| \le \Delta$ заменяется на (2).

Вопросы к А. В. Гасникову: (1) какая модель липшицева шума имелась в виду; (2) пересечение с `2610.05517` (систематическая липшицева ошибка в сильно выпуклом высокогладком случае); (3) нужен ли «кубик» адаптивности; (4) допустимо ли использовать LongTails в курсовой работе.

Список литературы

[1] А. В. Гасников, П. Е. Двуреченский, Ю. Е. Нестеров. Стохастические градиентные методы с неточным оракулом. arXiv:1411.4218 (2016).

[2] A. Gasnikov et al. Randomized gradient-free methods in convex optimization. arXiv:2211.13566.

[3] J. Duchi, M. Jordan, M. Wainwright, A. Wibisono. Optimal rates for zero-order convex optimization: the power of two function evaluations. IEEE Trans. Inf. Theory, 2015.

[4] A. Risteski, Y. Li. Algorithms and matching lower bounds for approximately-convex optimization. NeurIPS 2016.